



CS 2568/C3-5

รายงานความก้าวหน้าโครงการ ครั้งที่ 1

เว็บไซต์รวบรวมแหล่งประกาศราคาจัดซื้อจัดจ้างในจังหวัดขอนแก่น

Khon Kaen Province Public Procurement Portal

โดย

663380022-3 นายวงศ์ปกรณ์ ใจปัญญา

663380216-0 นายปกรณ์ จ่านงค์นารถ

อาจารย์ที่ปรึกษา ผศ. ดร.วชิราวุธ ธรรมวิเศษ

รายงานเล่มนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP353764 ระเบียบวิธีวิจัย

ภาคเรียนที่ 2 ปีการศึกษา 2568

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

(เดือน มีนาคม พ.ศ. 2569)

วงศ์ปรกรณ์ ใจปัญญา และ ปรกรณ์ จานงค์นารถ. 2569. เว็บไซต์รวบรวมแหล่งประกาศราคาจัดซื้อจัดจ้างในจังหวัด

ขอนแก่น. โครงการคอมพิวเตอร์ ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการ
คอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.

อาจารย์ที่ปรึกษา: ผศ. ดร.วชิราวุธ ธรรมวิเศษ

บทคัดย่อ

ภาวะความกระจุกกระจายและขาดมาตรฐานของข้อมูลการจัดซื้อจัดจ้างภาครัฐในระดับท้องถิ่น ส่งผลให้
ผู้ประกอบการเข้าถึงข้อมูลได้ยากและลดทอนความโปร่งใส โครงการนี้จึงมีวัตถุประสงค์เพื่อพัฒนาเว็บไซต์รวบรวมและ
จัดเก็บข้อมูลประกาศจัดซื้อจัดจ้างจากหน่วยงานนำร่องในจังหวัดขอนแก่นจำนวน 3 แห่ง ได้แก่ มหาวิทยาลัยขอนแก่น
เทศบาลนครขอนแก่น และโรงพยาบาลธัญญารักษ์ขอนแก่น พร้อมทั้งพัฒนากระบวนการสกัดข้อมูลจากเอกสารพีดีเอฟ
ด้วยเทคโนโลยีรู้จำอักขระด้วยแสงให้มีความแม่นยำสูง

วิธีการดำเนินงานวิจัยอาศัยกระบวนการสกัด แปลง และนำเข้าข้อมูล ร่วมกับเทคนิคการดึงข้อมูลจากหน้า
เว็บไซต์แบบอัตโนมัติ สำหรับการประมวลผลเอกสาร ได้มีการบูรณาการเทคโนโลยีรู้จำอักขระด้วยแสงที่รองรับภาษาไทย
ควบคู่กับการประมวลผลภาพเบื้องต้น เพื่อแปลงและอ่านข้อมูลจากเอกสารทั้งรูปแบบข้อความมาตรฐานและเอกสารที่
ผ่านการสแกน จากนั้นจึงทำการสกัดโครงสร้างสารสนเทศที่สำคัญด้วยเทคนิคการรู้จำรูปแบบข้อความเชิงกฎเกณฑ์ เพื่อ
นำไปจัดเก็บในระบบฐานข้อมูลและแสดงผลผ่านระบบเว็บแอปพลิเคชัน

ผลการดำเนินงานเบื้องต้นพบว่า ระบบสามารถวิเคราะห์โครงสร้างเว็บไซต์เป้าหมายและกำหนดฟิลด์ข้อมูล
มาตรฐานได้สำเร็จ โดยการทดสอบสกัดข้อความแสดงให้เห็นว่าเอกสารประเภทข้อความมาตรฐานมีแนวโน้มความ
คลาดเคลื่อนของคำร้อยละ 8.5 ในขณะที่เอกสารจากการสแกนยังต้องอาศัยกระบวนการทำความสะอาดและปรับปรุง
คุณภาพภาพที่เข้มข้นขึ้น ผลลัพธ์จากการนำระบบนี้ไปประยุกต์ใช้ จะช่วยลดต้นทุนด้านเวลาในการสืบค้นและ
เปรียบเทียบข้อมูลสำหรับผู้ประกอบการรายย่อย อีกทั้งยังช่วยยกระดับประสิทธิภาพการตรวจสอบข้อมูลของภาครัฐ
ตลอดจนสร้างความโปร่งใสและส่งเสริมการแข่งขันที่เท่าเทียมในระบบเศรษฐกิจระดับภูมิภาค

คำสำคัญ: การจัดซื้อจัดจ้างภาครัฐ, การรู้จำอักขระด้วยแสง, การดึงข้อมูลจากเว็บไซต์, การสกัดข้อมูลสารสนเทศ,
จังหวัดขอนแก่น

กิตติกรรมประกาศ

รายงานและโครงการคอมพิวเตอร์ฉบับนี้ สำเร็จลุล่วงไปได้ด้วยความสมบูรณ์เนื่องจากได้รับความเมตตาและคำชี้แนะอย่างดียิ่งจาก ผู้ช่วยศาสตราจารย์ ดร.วชิราวุธ ธรรมวิเศษ อาจารย์ที่ปรึกษาโครงการ ที่ได้สละเวลาอันมีค่าในการให้คำปรึกษา ตรวจสอบ ตลอดจนถ่ายทอดองค์ความรู้เชิงลึกด้านการพัฒนาระบบสถาปัตยกรรมซอฟต์แวร์และการสกัดข้อมูลเชิงวิเคราะห์ ซึ่งเป็นแนวทางอันประเสริฐที่ช่วยเป็นแนวทางให้คณะผู้จัดทำสามารถแก้ไขข้อบกพร่องต่างๆ ได้ คณะผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ โอกาสนี้

ขอกราบขอบพระคุณคณาจารย์ประจำวิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่นทุกท่าน ที่ได้ถ่ายทอดวิชาความรู้และวางรากฐานทางวิชาการด้านวิทยาการคอมพิวเตอร์ อันเป็นปัจจัยสำคัญที่ทำให้คณะผู้จัดทำสามารถนำทฤษฎีมาประยุกต์ใช้ในการแก้ปัญหาจริงได้อย่างมีประสิทธิภาพ

ท้ายที่สุดนี้ คณะผู้จัดทำขอกราบระลึกถึงพระคุณของบิดา มารดา และสมาชิกในครอบครัวทุกท่าน ที่คอยเป็นกำลังใจสำคัญ ตลอดจนให้การสนับสนุนทั้งด้านทุนทรัพย์และพลังใจเสมอมา รวมถึงขอขอบคุณเพื่อนนักศึกษาที่คอยแลกเปลี่ยนความคิดเห็นและให้ความช่วยเหลือซึ่งกันและกันจนโครงการนี้สำเร็จลุล่วงไปได้ด้วยดี

ผู้จัดทำ

วงศ์ปรกรณ์ ใจปัญญา

ปกรณ์ จ้านงค์นารถ

สารบัญ

สารบัญตาราง

สารบัญภาพ (เพื่อมี)

บทที่ 1

บทนำ

1. ความเป็นมาและความสำคัญของปัญหา

ระบบการจัดซื้อจัดจ้างของภาครัฐถือเป็นกลไกสำคัญที่มีบทบาทอย่างยิ่งในการขับเคลื่อนระบบเศรษฐกิจของประเทศไทย โดยในแต่ละปีมีเม็ดเงินหมุนเวียนเข้าสู่ระบบสูงถึง 1.3 ล้านล้านบาท (1) กิจกรรมดังกล่าวมิได้จำกัดอยู่เพียงส่วนกลาง แต่ยังครอบคลุมถึงการบริหารราชการส่วนภูมิภาคและส่วนท้องถิ่น หากพิจารณาบริบทของจังหวัดขอนแก่น ซึ่งมีสถานะเป็นศูนย์กลางทางเศรษฐกิจของภาคตะวันออกเฉียงเหนือตอนกลาง จะพบว่ามีโครงสร้างการปกครองส่วนท้องถิ่นรวมถึง 225 แห่ง (2) ประกอบกับหน่วยงานราชการอื่นๆ อีกเป็นจำนวนมาก ปริมาณธุรกรรมการจัดซื้อจัดจ้างในพื้นที่จึงมีสัดส่วนที่สูงและมีความหลากหลายอย่างมีนัยสำคัญ

อย่างไรก็ตาม ปัญหาหลักที่เด่นชัดในปัจจุบันคือ "สภาวะกระจัดกระจายของสารสนเทศ" (Information Fragmentation) แม้ว่าภาครัฐส่วนกลางจะมีความพยายามในการพัฒนาระบบการจัดซื้อจัดจ้างด้วยอิเล็กทรอนิกส์ (e-GP) เพื่อเป็นศูนย์กลางข้อมูล แต่ในทางปฏิบัติจริง หน่วยงานระดับท้องถิ่นและภูมิภาคส่วนใหญ่ยังคงเลือกที่จะเผยแพร่ประกาศผ่านเว็บไซต์หลักของตนเองแยกเป็นเอกเทศควบคู่กันไป ซึ่งบ่อยครั้งก่อให้เกิดความคลาดเคลื่อนและไม่ครบถ้วนของข้อมูลเมื่อเทียบกับฐานข้อมูลกลาง (3) สภาวะการณ์เช่นนี้ส่งผลกระทบโดยตรงต่อความโปร่งใส (Transparency) และก่อให้เกิดข้อจำกัดในการเข้าถึงข้อมูล โดยเฉพาะอย่างยิ่งสำหรับผู้ประกอบการวิสาหกิจขนาดกลางและขนาดย่อม (SMEs) ที่มักเผชิญอุปสรรคด้านทรัพยากรในการสืบค้นและติดตามข่าวสาร (4) นำไปสู่การเสียโอกาสในการแข่งขันอย่างเป็นธรรม

นอกจากปัญหาความกระจัดกระจายของแหล่งข้อมูลแล้ว รูปแบบของเอกสารที่ถูกเผยแพร่ยังเป็นอุปสรรคทางเทคนิคที่สำคัญ เนื่องจากประกาศและเอกสารประกวดราคาส่วนใหญ่อยู่ในรูปแบบไฟล์ PDF ซึ่งมีทั้งเอกสารที่สร้างจากโปรแกรมประมวลผลคำ (Text-based PDF) และเอกสารที่เกิดจากการสแกน (Scanned PDF) ซึ่งขาดโครงสร้างข้อมูลที่เป็นมาตรฐาน ทำให้การนำข้อมูลไปวิเคราะห์หรือตรวจสอบต่อทำได้ยากยิ่ง

ด้วยเหตุนี้ โครงการนี้จึงมุ่งนำเสนอแนวทางการแก้ปัญหาแบบบูรณาการ ผ่านการพัฒนาเว็บไซต์รวบรวมแหล่งประกาศราคาจัดซื้อจัดจ้างในจังหวัดขอนแก่น โดยประยุกต์ใช้เทคนิคการดึงข้อมูลจากเว็บไซต์ (Web Scraping) ร่วมกับกระบวนการนำเข้าและแปลงสภาพข้อมูล (ETL/ELT) พร้อมทั้งบูรณาการเทคโนโลยีการรู้จำอักขระด้วยแสง (Optical Character Recognition: OCR) ที่รองรับความซับซ้อนของภาษาไทย เพื่อดึงข้อมูลสารสนเทศที่สำคัญจากไฟล์ PDF ทุกประเภทอย่างเป็นระบบ การพัฒนาดังกล่าวไม่เพียงแต่ช่วยลดต้นทุนด้านเวลาและยกระดับขีดความสามารถในการ

แข่งขันของภาครัฐกิจ แต่ยังเป็นการวางรากฐานด้านข้อมูล (Data Foundation) ที่แข็งแกร่ง เพื่อสนับสนุนการกำกับดูแลและการตรวจสอบการใช้งบประมาณของภาครัฐให้เกิดประสิทธิภาพสูงสุด

2. วัตถุประสงค์ของโครงการ

2.1 เพื่อพัฒนาเว็บไซต์ที่สามารถรวบรวม จัดเก็บ และแสดงผลข้อมูลประกาศจัดซื้อจัดจ้างจากหน่วยงานรัฐอย่างน้อย 3 แห่งในจังหวัดขอนแก่น

2.2 เพื่อพัฒนาระบบการสกัดข้อมูลจากเอกสาร PDF ด้วยเทคโนโลยีรู้จำอักขระด้วยแสง (OCR) ให้ได้ความแม่นยำตามเกณฑ์ที่กำหนด

3. เป้าหมายและขอบเขต

3.1 ขอบเขตด้านแหล่งข้อมูลและประเภทเอกสาร

3.1.1 หน่วยงานภาครัฐเป้าหมายในจังหวัดขอนแก่น (กรณีศึกษา)

- (1) มหาวิทยาลัยขอนแก่น (ตัวแทนหน่วยงานการศึกษาขนาดใหญ่)
- (2) เทศบาลนครขอนแก่น (ตัวแทนองค์กรปกครองส่วนท้องถิ่น)
- (3) โรงพยาบาลธัญญารักษ์ขอนแก่น (ตัวแทนหน่วยงานด้านสาธารณสุข)

3.1.2 ประเภทของเอกสารที่ใช้ในการสกัดข้อมูล

- (1) เอกสาร PDF ที่มีข้อความ (Text-based PDF)
- (2) เอกสาร PDF ที่ได้จากการสแกน (Scanned PDF)

3.2 ขอบเขตด้านระบบและกลุ่มผู้ใช้งาน

3.2.1 กลุ่มผู้ใช้งานทั่วไป (Guest)

สามารถสืบค้นข้อมูล กรองหมวดหมู่/งบประมาณ และดาวน์โหลดเอกสาร PDF ดัชนีฉบับได้

3.2.2 กลุ่มผู้ใช้งานที่ลงทะเบียน (Registered User)

สามารถเข้าถึงฟังก์ชันบันทึกเงื่อนไขการค้นหา ดูประวัติย้อนหลัง และตั้งค่าระบบแจ้งเตือน (Alerts)

ประกาศใหม่ผ่านเว็บไซต์และอีเมลได้

4. ประโยชน์ที่คาดว่าจะได้รับ

4.1 ช่วยลดความเหลื่อมล้ำทางสารสนเทศ ทำให้ผู้ประกอบการโดยเฉพาะกลุ่ม SMEs สามารถเข้าถึงโอกาสในการประกวดราคาได้อย่างสะดวกรวดเร็ว รวมถึงลดต้นทุนทางเวลา

4.2 เกิดแนวทางปฏิบัติ (Guidelines) ด้านกระบวนการรวบรวม แปลงสภาพ และยกระดับคุณภาพข้อมูลจากเอกสารไร้โครงสร้าง ซึ่งสามารถนำไปทำซ้ำและขยายผลกับหน่วยงานอื่นได้

บทที่ 2

งานวิจัยและทฤษฎีที่เกี่ยวข้อง

1. งานวิจัยที่เกี่ยวข้อง

1.1 งานวิจัยด้านระบบสารสนเทศและการจัดการข้อมูลการจัดซื้อจัดจ้างภาครัฐ

บริบทของการบริหารจัดการข้อมูลภาครัฐในประเทศไทยยังคงเผชิญกับข้อจำกัดเชิงประจักษ์หลายประการ โดยเฉพาะอย่างยิ่งในระดับองค์กรปกครองส่วนท้องถิ่น จากการศึกษาของ ศราวุฒิ ธรรมวิเศษ และคณะ (5) ซึ่งได้ประเมินสภาพปัญหาการใช้งานระบบจัดซื้อจัดจ้างภาครัฐด้วยอิเล็กทรอนิกส์ (e-GP) ในพื้นที่จังหวัดสุรินทร์ พบว่าอุปสรรคสำคัญประการหนึ่งเกิดจากความซับซ้อนของระเบียบปฏิบัติและข้อกำหนดที่ส่งผลให้กระบวนการทำงานขาดความคล่องตัว ประกอบกับข้อมูลสารสนเทศที่กระจัดกระจาย งานวิจัยดังกล่าวจึงเสนอแนะให้มีการสร้างเครือข่ายบูรณาการข้อมูลเพื่อลดความซับซ้อนในการทำงาน

สอดคล้องกับการศึกษาของ เอกลักษณ์ สงแทน และคณะ (6) ที่มุ่งแก้ไขปัญหาค่าซ้ำในกระบวนการจัดซื้อจัดจ้างโดยพัฒนาระบบติดตามผ่านเทคโนโลยีคลาวด์พื้นฐานอย่าง Google Sheets ผลสัมฤทธิ์จากงานวิจัยนี้ชี้ให้เห็นว่า การรวมศูนย์ข้อมูล (Data Centralization) ให้อยู่ในรูปแบบที่ผู้ใช้งานสามารถเข้าถึงและตรวจสอบได้ง่ายตามเวลาจริง (Real-time) ไม่เพียงแต่ช่วยลดระยะเวลาดำเนินการ แต่ยังยกระดับความโปร่งใสและประสิทธิภาพในการเบิกจ่ายงบประมาณได้อย่างมีนัยสำคัญ องค์ความรู้นี้จึงเป็นแรงผลักดันสำคัญในการออกแบบเว็บไซต์รวบรวมประกาศจัดซื้อจัดจ้างของจังหวัดขอนแก่นให้มีสถาปัตยกรรมที่เน้นความเรียบง่ายแต่เปี่ยมด้วยประสิทธิภาพในการเข้าถึงข้อมูล

1.2 งานวิจัยด้านการสกัดข้อมูลและการจัดการเอกสารอิเล็กทรอนิกส์

1.2.1 การประเมินและเปรียบเทียบเครื่องมือสกัดข้อมูลจากแฟ้มข้อมูล PDF

เอกสารที่ใช้ในกระบวนการจัดซื้อจัดจ้างส่วนใหญ่มักถูกจัดเก็บในรูปแบบ PDF ซึ่งมีความหลากหลายทางโครงสร้าง การเลือกใช้เครื่องมือที่เหมาะสมจึงเป็นความท้าทายหลัก Adhikari และ Agarwal (7) ได้ดำเนินการศึกษาเปรียบเทียบเชิงลึกเกี่ยวกับประสิทธิภาพของเครื่องมือวิเคราะห์แฟ้มข้อมูล PDF (PDF Parsing Tools) จำนวน 10 ชนิด โดยจำแนกตามหมวดหมู่เอกสาร ผลการทดสอบยืนยันว่าไม่มีเครื่องมือใดที่มีประสิทธิภาพสมบูรณ์แบบในทุกสถานการณ์ เครื่องมือที่อาศัยกฎเกณฑ์ (Rule-based) เช่น PyMuPDF ทำผลงานได้ดีเยี่ยมในการดึงข้อความทั่วไป แต่กลับประสบปัญหาเมื่อต้องจัดการกับเอกสารทางวิทยาศาสตร์หรือเอกสารที่มีตารางไร้เส้นขอบ (Border-less Tables) ในทาง

กลับกัน เครื่องมือที่พัฒนามาบนรากฐานของการเรียนรู้เชิงลึก (Deep Learning) เช่น Table Transformer (TATR) กลับแสดงศักยภาพที่โดดเด่นในการวิเคราะห์โครงสร้างข้อมูลที่ซับซ้อน ข้อค้นพบนี้เป็นแนวทางสำคัญให้โครงการนี้ต้องออกแบบระบบที่มีความยืดหยุ่น รองรับทั้งเอกสารประเภท Text-based และ Scanned PDF

1.2.2 การประยุกต์ใช้เทคโนโลยีขั้นสูงในการสกัดข้อมูลและการรู้จำอักขระ

(1) การใช้เทคโนโลยี OCR และ LLM ในบริบทของเอกสารจัดซื้อจัดจ้าง

งานวิจัยของ Taoufik และ Azmani (8) ถือเป็นต้นแบบที่สะท้อนให้เห็นถึงความเป็นไปได้ในการพัฒนาระบบดึงข้อมูลอัตโนมัติแบบครบวงจร (End-to-End) ในบริบทของเอกสารจัดซื้อจัดจ้างของประเทศโมร็อกโก คณะผู้วิจัยได้บูรณาการกระบวนการ Web Scraping เพื่อดึงเอกสาร รวบรวมเข้ากับเทคโนโลยี PaddleOCR เพื่อแปลงภาพเป็นข้อความดิจิทัล และใช้แบบจำลองภาษาขนาดใหญ่ (LLM) อย่าง Mistral ในการสกัดข้อมูลเชิงลึก สิ่งที่น่าสนใจอย่างยิ่งคือการให้ความสำคัญกับขั้นตอนการทำความสะอาดข้อมูล (Post-extraction Cleaning) โดยใช้เทคนิคการจับคู่สายอักขระแบบคลุมเครือ (Fuzzy Matching) เพื่อแก้ปัญหาข้อผิดพลาดที่ตรงกัน ซึ่งเป็นอุปสรรคที่พบได้บ่อยในเอกสารราชการ

(2) การวิเคราะห์โครงสร้างเอกสารและการสกัดเอนทิตีเพื่อเพิ่มความแม่นยำ

นอกจากนี้ เพื่อจัดการกับอุปสรรคด้านความยาวและความซับซ้อนของเอกสาร Liu และ Li (9) ได้นำเสนอกรอบแนวคิด AutoIE สำหรับการสกัดข้อมูลอัตโนมัติจากวรรณกรรมทางวิทยาศาสตร์ โดยใช้แบบจำลอง SBERT ที่ผสมผสานคุณลักษณะเชิงความหมายที่หลากหลาย (Multi-semantic Feature Fusion) เข้าด้วยกัน เทคนิคนี้ช่วยให้ระบบสามารถระบุตำแหน่งของบล็อกข้อมูล (Layout Analysis) และเชื่อมโยงความสัมพันธ์ของเอนทิตี (Named Entity Recognition) ได้อย่างแม่นยำ แม้ข้อมูลเป้าหมายจะถูกซ่อนอยู่ในบริบทที่หนาแน่น งานวิจัยนี้แนะนำแนวทางการกรองข้อมูลรบกวน (Noise Reduction) ซึ่งสามารถนำมาประยุกต์ใช้ในการสกัดข้อมูลสารสนเทศที่สำคัญ (เช่น วงเงินงบประมาณ, วันที่เปิดซอง) จากเอกสารขอบเขตงาน (TOR) ของหน่วยงานรัฐได้อย่างมีประสิทธิภาพ

2. ทฤษฎีที่เกี่ยวข้อง

2.1 กฎหมายและกระบวนการจัดการข้อมูลภาครัฐ

2.1.1 การบริหารพัสดุภาครัฐและข้อกำหนดทางกฎหมาย

กลไกการบริหารพัสดุและการจัดซื้อจัดจ้างของหน่วยงานภาครัฐไทย ดำเนินการภายใต้กรอบของพระราชบัญญัติการจัดซื้อจัดจ้างและการบริหารพัสดุภาครัฐ พ.ศ. 2560 ซึ่งมีเป้าหมายเชิงยุทธศาสตร์ในการสร้างมาตรฐานความโปร่งใสและเพิ่มประสิทธิภาพการใช้งบประมาณแผ่นดิน โดยกฎหมายฉบับนี้กำหนดให้หน่วยงานของรัฐต้องเปิดเผยข้อมูลผ่านระบบเครือข่ายสารสนเทศของกรมบัญชีกลาง (10) เพื่อตอบสนองต่อข้อบังคับดังกล่าว ระบบจัดซื้อจัดจ้างภาครัฐด้วยอิเล็กทรอนิกส์ (e-GP) จึงถูกพัฒนาขึ้นเพื่อเป็นฐานข้อมูลกลาง อย่างไรก็ตาม ในทางปฏิบัติพบว่า

หน่วยงานระดับท้องถิ่นจำนวนมากยังคงใช้วิธีเผยแพร่ประกาศผ่านเว็บไซต์ของตนเองแยกต่างหาก ส่งผลให้เกิดสถานะข้อมูลกระจัดกระจายและเกิดความคลาดเคลื่อนเมื่อเทียบกับฐานข้อมูลส่วนกลาง (3)

2.1.2 สถาปัตยกรรมการรวบรวมข้อมูลผ่านกระบวนการ ETL และ ELT

การบริหารจัดการข้อมูลขนาดใหญ่ที่มาจากแหล่งสารสนเทศอันหลากหลาย จำเป็นต้องพึ่งพาสถาปัตยกรรมข้อมูลที่มีประสิทธิภาพ โดยดั้งเดิมนั้นมักอาศัยกระบวนการ ETL ซึ่งประกอบด้วยการดึงข้อมูลจากต้นทาง (Extract) การแปลงสภาพข้อมูลให้ได้มาตรฐาน (Transform) และการนำเข้าสู่คลังข้อมูล (Load) ทว่าในบริบทของเทคโนโลยีการประมวลผลแบบคลาวด์ในปัจจุบัน สถาปัตยกรรมแบบ ELT ได้รับความนิยมเพิ่มขึ้นอย่างมีนัยสำคัญเนื่องจากวิธีการนี้จะนำเข้าสู่ข้อมูลดิบเข้าสู่ระบบจัดเก็บ (Data Lake) ก่อน จากนั้นจึงอาศัยขีดความสามารถของระบบปลายทางในการแปลงสภาพข้อมูลภายหลัง ซึ่งมอบความยืดหยุ่นในการรองรับโครงสร้างข้อมูลที่ซับซ้อนได้ดียิ่งขึ้น (11)

2.2 เทคโนโลยีปัญญาประดิษฐ์และการดึงข้อมูล

2.2.1 วิทยาการสกัดข้อมูลเว็บ (Web Scraping) และกอบจริยธรรม

วิทยาการ Web Scraping เป็นเทคนิคเชิงวิศวกรรมที่ใช้สำหรับการดึงข้อมูลขนาดใหญ่จากเว็บไซต์เป้าหมายโดยอัตโนมัติ แม้ว่าพระราชบัญญัติข้อมูลข่าวสารของราชการ พ.ศ. 2540 จะรับรองสิทธิสาธารณะในการเข้าถึงข้อมูลภาครัฐ ทว่าการประยุกต์ใช้เทคนิคนี้ต้องกระทำภายใต้ความตระหนักถึงพระราชบัญญัติว่าด้วยการกระทำความผิดเกี่ยวกับคอมพิวเตอร์ พ.ศ. 2550 อย่างเคร่งครัด (12) (13) ตลอดจนต้องยึดมั่นในหลักจริยธรรมทางเทคโนโลยี อาทิ การเคารพข้อกำหนดในไฟล์ robots.txt และการควบคุมความถี่ในการส่งคำร้องขอ (Rate Limiting) เพื่อหลีกเลี่ยงผลกระทบเชิงลบต่อเสถียรภาพของเครื่องแม่ข่ายต้นทาง (14)

2.2.2 การรู้จำอักขระด้วยแสง (Optical Character Recognition: OCR)

เทคโนโลยี OCR ทำหน้าที่สำคัญในการแปลงสภาพภาพถ่ายหรือเอกสารสแกนให้กลายเป็นข้อความดิจิทัลที่คอมพิวเตอร์สามารถนำไปวิเคราะห์ต่อได้ กระบวนการดังกล่าวประกอบด้วยขั้นตอนการปรับปรุงคุณภาพภาพ (Pre-processing) การแยกแยะองค์ประกอบภาพ (Segmentation) การจดจำรูปแบบ (Pattern Recognition) และการตรวจสอบความถูกต้องสอดคล้อง (Post-processing) (15)

(1) การประยุกต์ใช้โครงข่ายประสาทเทียมในการรู้จำภาษาไทย

ในยุคปัจจุบัน เทคโนโลยีการเรียนรู้เชิงลึก (Deep Learning) เช่น Convolutional Neural Networks (CNN) และ Recurrent Neural Networks (RNN) ได้ถูกนำมาใช้เพื่อยกระดับความแม่นยำในการอ่านเอกสารที่มีสภาพสมบูรณ์ต่ำ (16) โดยเฉพาะอย่างยิ่งกับภาษาไทยซึ่งมีลักษณะโครงสร้างซับซ้อนจากการวางสระและวรรณยุกต์ซ้อนทับกันหลายระดับ การใช้สถาปัตยกรรมเครือข่ายประสาทที่ผ่านการฝึกฝนเฉพาะทางจึงเป็นสิ่งจำเป็นอย่างยิ่ง (17)

(2) เครื่องมือโอเพนซอร์ส Tesseract OCR

Tesseract ถือเป็นหนึ่งในซอฟต์แวร์ประมวลผลอักขระแบบเปิดเผยซอร์สโค้ดที่ทรงประสิทธิภาพที่สุดซึ่งได้รับการพัฒนาโดย Google โดยตั้งแต่เวอร์ชัน 4.0 เป็นต้นมา ได้มีการผสานเทคโนโลยี Long Short-Term Memory (LSTM) เข้ามาเป็นแกนหลัก ส่งผลให้ศักยภาพในการวิเคราะห์บริบทของภาษาที่ซับซ้อนอย่างภาษาไทยมีประสิทธิภาพสูงขึ้นอย่างก้าวกระโดด (15)

2.3 ทฤษฎีและมาตรวัดประเมินประสิทธิภาพระบบ

2.3.1 อัตราความผิดพลาดของคำ (Word Error Rate: WER)

WER คือมาตรวัดมาตรฐานสากลที่ใช้ในการประเมินประสิทธิภาพของเทคโนโลยีรู้จำอักขระและเสียงสะท้อน โดยอาศัยอัลกอริทึม Levenshtein Distance ในการคำนวณสัดส่วนของข้อผิดพลาด เปรียบเทียบกับข้อความต้นฉบับ การประเมินนี้จะพิจารณาจากผลรวมของการแทนที่คำผิด (Substitutions) การตกหล่น (Deletions) และการแทรกคำเกิน (Insertions) ทหารด้วยจำนวนคำทั้งหมดในชุดข้อมูลอ้างอิง (18) โดยค่า WER ที่ต่ำจะบ่งชี้ถึงความแม่นยำของระบบที่สูงขึ้น โดยคำนวณจากสูตร

$$WER = \frac{S + D + I}{N} \times 100\%$$

โดยที่ S คือจำนวนคำที่ถูกแทนที่ (Substitutions), D คือจำนวนคำที่ถูกลบออก (Deletions), I คือจำนวนคำที่ถูกแทรกเข้ามา (Insertions) และ N คือจำนวนคำทั้งหมดในข้อความต้นฉบับ

2.3.2 มาตรวัดความแม่นยำและการดึงข้อมูล (F1-Score)

F1-Score เป็นมาตรวัดทางสถิติที่ใช้ประเมินประสิทธิภาพของโมเดลการจำแนกประเภท (Classification) และการสกัดข้อมูล (Information Extraction) โดยเป็นค่าเฉลี่ยฮาร์มอนิก (Harmonic Mean) ระหว่าง Precision และ Recall

Precision (ความแม่นยำ) คืออัตราส่วนของข้อมูลที่ทำนายถูกต้องต่อข้อมูลที่ทำนายทั้งหมด ซึ่งบ่งบอกว่าเมื่อระบบทำนายว่าเป็นบวก มีความน่าเชื่อถือเพียงใด คำนวณจากสูตร

$$Precision = \frac{TP}{TP + FP}$$

Recall (ความครบถ้วน) คืออัตราส่วนของข้อมูลที่ทำนายถูกต้องต่อข้อมูลที่ควรทำนายถูกทั้งหมด ซึ่งบ่งบอกว่าระบบสามารถค้นพบข้อมูลที่ต้องการได้ครบถ้วนเพียงใด คำนวณจากสูตร

$$Recall = \frac{TP}{TP + FN}$$

โดยที่ TP (True Positive) คือจำนวนที่ทำนายถูกต้องว่าเป็นบวก, FP (False Positive) คือจำนวนที่ทำนายผิดว่าเป็นบวก และ FN (False Negative) คือจำนวนที่ทำนายผิดว่าเป็นลบ

F1-Score คำนวณจากสูตร

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

F1-Score มีค่าตั้งแต่ 0 ถึง 1 โดยค่า 1 แสดงถึงประสิทธิภาพที่สมบูรณ์แบบ มาตรฐานนี้เหมาะสมสำหรับการประเมินงานสกัดข้อมูลที่ต้องการความสมดุลระหว่างความแม่นยำและความครบถ้วน

บทที่ 3

วิธีการดำเนินงาน

1. การศึกษาและวิเคราะห์แหล่งข้อมูล

ขั้นตอนแรกเป็นการศึกษาและวิเคราะห์แหล่งข้อมูลเป้าหมาย เพื่อทำความเข้าใจโครงสร้างเว็บไซต์ รูปแบบการจัดเก็บข้อมูล และข้อจำกัดทางเทคนิค โดยมีรายละเอียดดังนี้

1.1 หน่วยงานเป้าหมาย

โครงการนี้มุ่งเน้นการรวบรวมข้อมูลจากหน่วยงานภาครัฐในจังหวัดขอนแก่น จำนวน 3 หน่วยงานเป็นกรณีศึกษา ได้แก่

1.1.1 ระบบเผยแพร่ข้อมูลข่าวสารการจัดซื้อจัดจ้าง มหาวิทยาลัยขอนแก่น เป็นหน่วยงานการศึกษาขนาดใหญ่ที่มีการจัดซื้อจัดจ้างหลากหลายประเภท ทั้งครุภัณฑ์ วัสดุ และงานก่อสร้าง

1.1.2 เทศบาลนครขอนแก่น เป็นองค์กรปกครองส่วนท้องถิ่นที่มีงบประมาณจัดซื้อจัดจ้างสูง และมีประกาศจำนวนมาก

1.1.3 โรงพยาบาลธัญญารักษ์ขอนแก่น เป็นหน่วยงานด้านสาธารณสุขที่มีการจัดซื้อจัดจ้างเวชภัณฑ์และอุปกรณ์การแพทย์

1.2 การวิเคราะห์โครงสร้างเว็บไซต์

ดำเนินการวิเคราะห์โครงสร้างเว็บไซต์ของแต่ละหน่วยงาน ประกอบด้วย

1.2.1 ศึกษาโครงสร้าง HTML และ CSS ของหน้าเว็บประกาศ

1.2.2 วิเคราะห์รูปแบบ URL และพารามิเตอร์ที่ใช้ในการเรียกดูข้อมูล

1.2.3 ตรวจสอบไฟล์ robots.txt เพื่อให้การรวบรวมข้อมูลเป็นไปตามจริยธรรม (14)

1.2.4 ระบุตำแหน่งของข้อมูลสำคัญ เช่น ชื่อโครงการ งบประมาณ วันที่ประกาศ และลิงก์ไฟล์ PDF

1.3 การจำแนกประเภทเอกสาร

จำแนกประเภทเอกสารที่พบในแต่ละหน่วยงาน ออกเป็น 2 ประเภทหลัก

1.3.1 เอกสาร PDF ที่มีข้อความ (Text-based PDF) เป็นไฟล์ที่ถูกสร้างหรือส่งออกจากโปรแกรมประมวลผลคำโดยตรง สามารถคัดลอกข้อความได้

1.3.2 เอกสาร PDF จากการสแกน (Scanned PDF) เป็นไฟล์ที่เกิดจากการสแกนเอกสารฉบับจริง ข้อมูลภายในอยู่ในรูปแบบรูปภาพ

2. การรวบรวมชุดข้อมูล (Data Collection)

ขั้นตอนนี้เป็นการพัฒนาโปรแกรมรวบรวมข้อมูลจากแหล่งข้อมูลเป้าหมาย โดยใช้เทคนิค Web Scraping

ตารางที่ 1 เครื่องมือที่ใช้ในการรวบรวมข้อมูล

เครื่องมือ	เวอร์ชัน	วัตถุประสงค์การใช้งาน
Python	3.10+	ภาษาโปรแกรมหลัก
BeautifulSoup	4.x	แยกวิเคราะห์โครงสร้าง HTML
Requests	2.x	ส่งคำขอ HTTP เพื่อดึงข้อมูลจากเว็บไซต์
Pandas	2.x	จัดการและจัดเก็บข้อมูลในรูปแบบตาราง

2.1 ขั้นตอนการรวบรวมข้อมูล

2.1.1 ดึงรายการประกาศจากหน้าเว็บไซต์ พัฒนาสคริปต์ Python เพื่อดึงข้อมูลจากหน้ารายการประกาศของแต่ละหน่วยงาน โดยสกัดข้อมูลพื้นฐาน ได้แก่

- (1) ชื่อประกาศ
- (2) วันที่ประกาศ
- (3) หน่วยงานเจ้าของโครงการ
- (4) ลิงก์ไปยังหน้ารายละเอียด
- (5) ลิงก์ดาวน์โหลดไฟล์ PDF

2.1.2 ดาวน์โหลดไฟล์ PDF แบบ ดาวน์โหลดไฟล์ PDF ที่แนบมากับแต่ละประกาศ และจัดเก็บในโครงสร้างโฟลเดอร์ที่เป็นระบบ

2.1.3 จำกัดอัตราการเข้าถึง (Rate Limiting) กำหนดช่วงเวลาหน่วง (delay) ระหว่างการส่งคำขอแต่ละครั้ง เพื่อไม่ให้กระทบต่อประสิทธิภาพของเซิร์ฟเวอร์ต้นทาง ตามหลักจริยธรรมในการรวบรวมข้อมูล (14)

2.2 โครงสร้างข้อมูลที่รวบรวมจากหน้าเว็บไซต์

ข้อมูลที่สกัดจากหน้าเว็บไซต์ประกาศ ประกอบดังตารางต่อไปนี้

ตารางที่ 2 โครงสร้างข้อมูล

ลำดับ	ฟิลด์ข้อมูล	คำอธิบาย	ประเภทข้อมูล
1	รหัสประกาศ	รหัสเฉพาะของแต่ละประกาศ	String

ลำดับ	ฟิลด์ข้อมูล	คำอธิบาย	ประเภทข้อมูล
2	ชื่อประกาศ	ชื่อโครงการหรืองานจัดซื้อจัดจ้าง	String
3	หน่วยงาน	ชื่อหน่วยงานเจ้าของโครงการ	String
4	วิธีการจัดหา	วิธีการจัดซื้อจัดจ้าง เช่น e-bidding, เฉพาะเจาะจง	String
5	งบประมาณ	วงเงินงบประมาณ	Decimal
6	วันที่ประกาศ	วันที่เผยแพร่ประกาศ	Date
7	วันที่สิ้นสุด	วันสุดท้ายของการรับเอกสาร	Date
8	ลิงก์ PDF	URL ของไฟล์เอกสารแนบ	String
9	แหล่งที่มา	URL ของหน้าเว็บต้นทาง	String

3. การประมวลผลเอกสารเบื้องต้น (Document Pre-processing)

เพื่อสร้างกระบวนการสกัดข้อมูลที่เป็นมาตรฐานเดียวกัน จะดำเนินการประมวลผลเอกสาร PDF ก่อนเข้าสู่กระบวนการ OCR

3.1 การแปลง PDF เป็นรูปภาพ

แปลงเอกสาร PDF ทุกฉบับ (ทั้ง Text-based และ Scanned) ให้อยู่ในรูปแบบไฟล์รูปภาพ เพื่อให้เอกสารทุกฉบับเข้าสู่กระบวนการ OCR ได้อย่างสอดคล้องกัน โดยใช้เครื่องมือดังนี้

ตารางที่ 3 เครื่องมือที่ใช้ในการแปลงเอกสาร

เครื่องมือ	วัตถุประสงค์
pdf2image	แปลง PDF เป็นรูปภาพรายหน้า
Pillow (PIL)	จัดการและปรับแต่งรูปภาพ

3.2 การปรับปรุงคุณภาพภาพ (Image Enhancement)

ดำเนินการปรับปรุงคุณภาพภาพก่อนเข้าสู่กระบวนการ OCR เพื่อเพิ่มความแม่นยำในการรู้จำอักขระประกอบด้วย

3.2.1 การปรับขนาด (Resizing) ปรับความละเอียดของภาพให้เหมาะสม (300 DPI)

3.2.2 การแปลงเป็นภาพขาวดำ (Grayscale Conversion) ลดความซับซ้อนของภาพ

3.2.3 การปรับความคมชัด (Contrast Enhancement) เพิ่มความแตกต่างระหว่างตัวอักษรและพื้นหลัง

3.2.4 การลดสัญญาณรบกวน (Noise Reduction) กำจัดจุดรบกวนในภาพ

3.2.5 การปรับความเอียง (Deskewing) แก้ไขภาพที่เอียงจากการสแกน

4. การสกัดข้อความด้วยเทคโนโลยี OCR

นำไฟล์รูปภาพที่ผ่านการประมวลผลเบื้องต้นเข้าสู่กระบวนการรู้จำอักขระด้วยแสง (OCR)

4.1 เครื่องมือ OCR ที่ใช้

โครงการนี้เลือกใช้ Tesseract OCR เวอร์ชัน 5.x ซึ่งเป็นเครื่องมือโอเพนซอร์สที่พัฒนาโดย Google และรองรับภาษาไทย (15) โดยมีเหตุผลในการเลือกใช้ดังนี้

- 4.1.1 เป็นซอฟต์แวร์โอเพนซอร์ส ไม่มีค่าใช้จ่ายด้านลิขสิทธิ์
- 4.1.2 รองรับภาษาไทยด้วยโมเดล LSTM ที่ได้รับการฝึกสอนมาแล้ว
- 4.1.3 มีชุมชนผู้ใช้งานขนาดใหญ่และมีเอกสารประกอบครบถ้วน
- 4.1.4 สามารถปรับแต่งพารามิเตอร์ได้ตามความต้องการ

4.2 การตั้งค่า Tesseract OCR

เครื่องมือ: Tesseract OCR 5.x

ภาษา: Thai (tha) + English (eng)

โมเดล: LSTM only (--oem 1)

Page Segmentation Mode: Automatic (--psm 3)

4.3 ขั้นตอนการสกัดข้อความ

- 4.3.1 โหลดรูปภาพที่ผ่านการ Pre-processing
- 4.3.2 เรียกใช้ Tesseract OCR พร้อมพารามิเตอร์ที่กำหนด
- 4.3.3 รับผลลัพธ์เป็นข้อความดิบ (Raw Text)
- 4.3.4 จัดเก็บข้อความดิบพร้อมข้อมูลอ้างอิง (ชื่อไฟล์ต้นทาง หมายเลขหน้า)

5. การสกัดและจัดโครงสร้างข้อมูลสารสนเทศ (Information Extraction)

นำข้อความดิบที่ได้จากกระบวนการ OCR มาสกัดข้อมูลสำคัญและจัดเก็บในโครงสร้างที่กำหนด

5.1 ข้อมูลเป้าหมายที่ต้องการสกัดจากเอกสาร PDF

ตารางที่ 4 ข้อมูลเป้าหมายที่ต้องการสกัด

ลำดับ	ฟิลด์ข้อมูล	คำอธิบาย
1	ชื่องาน/โครงการ	ชื่อเต็มของงานจัดซื้อจัดจ้าง
2	หน่วยงานเจ้าของโครงการ	ชื่อหน่วยงานที่รับผิดชอบ
3	งบประมาณโครงการ	วงเงินงบประมาณหรือราคากลาง

4	วันที่ประกาศ	วันที่ออกประกาศ
5	วันที่เปิดซอง	วันที่กำหนดเปิดซองเสนอราคา
6	รายการพัสดุ	รายละเอียดสินค้าหรือบริการ
7	ข้อกำหนดทางเทคนิค	TOR หรือ Specification
8	รายชื่อคณะกรรมการ	ชื่อคณะกรรมการจัดซื้อจัดจ้าง

5.2 เทคนิคการสกัดข้อมูล

ใช้เทคนิคการสกัดข้อมูลแบบ Rule-based ร่วมกับ Regular Expression โดยอาศัยรูปแบบ (Pattern) ที่พบในเอกสารจัดซื้อจัดจ้างมาตรฐาน

5.2.1 Pattern Matching กำหนดรูปแบบการค้นหาสำหรับแต่ละฟิลด์ข้อมูล เช่น

(1) งบประมาณ: r'งบประมาณ[:\s]*([0-9,]+)\s*บาท'

(2) วันที่: r'วันที่\s*(\d{1,2})\s*(มกราคม|กุมภาพันธ์|...)\s*(\d{4})'

5.2.2 Keyword-based Extraction ค้นหาคำสำคัญ (Keyword) แล้วสกัดข้อความที่อยู่ใกล้เคียง

5.2.3 Section Detection แบ่งเอกสารออกเป็นส่วน ๆ ตามหัวข้อ แล้วสกัดข้อมูลจากแต่ละส่วน

5.3 การตรวจสอบและทำความสะอาดข้อมูล (Data Validation and Cleaning)

5.3.1 ตรวจสอบความถูกต้องของรูปแบบ เช่น ตรวจสอบว่าวันที่อยู่ในรูปแบบที่ถูกต้อง งบประมาณเป็นตัวเลข

5.3.2 เปรียบเทียบกับข้อมูลอ้างอิง เปรียบเทียบข้อมูลที่สกัดได้จาก PDF กับข้อมูลจากหน้าเว็บไซต์ เพื่อตรวจสอบความถูกต้อง


5.3.3 จัดการข้อมูลซ้ำซ้อน ตรวจสอบและลบข้อมูลประกาศที่ซ้ำกัน

5.3.4 ทำให้ข้อมูลเป็นมาตรฐาน (Normalization) เช่น แปลงรูปแบบวันที่ให้เป็นมาตรฐานเดียวกัน

6. การพัฒนาระบบและส่วนติดต่อผู้ใช้ (System Development)

พัฒนาเว็บแอปพลิเคชันสำหรับให้ผู้ใช้งานสามารถค้นหาและเข้าถึงข้อมูลประกาศจัดซื้อจัดจ้าง

ตารางที่ 5 สถาปัตยกรรมระบบ



ตารางที่ 6 เครื่องมือและเทคโนโลยีที่ใช้ในการพัฒนา

ส่วนประกอบ	เทคโนโลยี	วัตถุประสงค์
Frontend	HTML, CSS, JavaScript	สร้างส่วนติดต่อผู้ใช้
Backend	PHP/Laravel	จัดการ Logic และ API
Database	PostgreSQL	จัดเก็บข้อมูลประกาศ
Web Server	Nginx	ให้บริการเว็บไซต์
Hosting	Hostinger VPS	เซิร์ฟเวอร์สำหรับ Deploy

6.1 ฟังก์ชันการทำงานของระบบ

6.1.1 สำหรับผู้ใช้ทั่วไป (Guest)

- (1) ค้นหาประกาศด้วยคำค้น (Keyword Search)
- (2) กรองข้อมูลตามหมวดหมู่ (หน่วยงาน, วิธีการจัดหา, ประเภทงาน)
- (3) กรองตามช่วงงบประมาณ
- (4) ดาวน์โหลดเอกสาร PDF ด่วนฉบับ

6.1.2 สำหรับผู้ใช้ที่ลงทะเบียน (Registered User)

- (1) ฟังก์ชันทั้งหมดของผู้ใช้ทั่วไป

- (2) บันทึกเงื่อนไขการค้นหาที่ใช้บ่อย
- (3) ดูประวัติการค้นหาและการเข้าชม
- (4) ตั้งค่าการแจ้งเตือนประกาศใหม่ตามเงื่อนไขที่กำหนด
- (5) เลือกช่องทางการแจ้งเตือน (ในเว็บไซต์ หรือ อีเมล)

6.2 การออกแบบฐานข้อมูล

ตารางที่ 6 เครื่องมือและเทคโนโลยีที่ใช้ในการพัฒนา

ตาราง	คำอธิบาย	ฟิลด์หลัก
announcements	ข้อมูลประกาศจัดซื้อจัดจ้าง	id, title, agency, budget, publish_date, ...
agencies	ข้อมูลหน่วยงาน	id, name, type, website
documents	ข้อมูลเอกสาร PDF	id, announcement_id, file_path, extracted_text
users	ข้อมูลผู้ใช้ที่ลงทะเบียน	id, email, password_hash, created_at
alerts	การตั้งค่าแจ้งเตือน	id, user_id, conditions, channel

7. การประเมินผลและสรุปผล (Evaluation)

ขั้นตอนสุดท้ายเป็นการประเมินประสิทธิภาพของระบบในด้านความถูกต้องและความครบถ้วนของข้อมูล

7.1 การสร้างชุดข้อมูลอ้างอิง (Ground Truth)

เพื่อประเมินประสิทธิภาพของระบบ จำเป็นต้องสร้างชุดข้อมูลอ้างอิงที่ถูกต้อง โดยดำเนินการดังนี้

7.1.1 การสุ่มตัวอย่างเอกสาร สุ่มเลือกเอกสาร PDF จากแต่ละหน่วยงาน หน่วยงานละ 30 ฉบับ รวม 90 ฉบับ โดยแบ่งเป็น

- (1) Text-based PDF: 15 ฉบับต่อหน่วยงาน
- (2) Scanned PDF: 15 ฉบับต่อหน่วยงาน

7.1.2 การสร้าง Ground Truth สำหรับ OCR ให้ผู้วิจัยอ่านและพิมพ์ข้อความจากเอกสารตัวอย่างด้วยตนเอง เพื่อใช้เป็นข้อความอ้างอิงในการคำนวณ WER

7.1.3 การสร้าง Ground Truth สำหรับ Information Extraction ให้ผู้วิจัยสกัดข้อมูลสำคัญจากเอกสารตัวอย่างด้วยตนเอง และบันทึกในรูปแบบตารางที่กำหนด

7.2 มาตรวัดที่ใช้ในการประเมิน

7.2.1 Word Error Rate (WER) สำหรับประเมินความแม่นยำของ OCR

$$WER = \frac{S + D + I}{N} \times 100\%$$

โดยที่ S = จำนวนคำที่ถูกแทนที่, D = จำนวนคำที่ถูกลบ, I = จำนวนคำที่ถูกแทรก, N = จำนวนคำทั้งหมดใน Ground Truth เกณฑ์การยอมรับ: WER < 10%

7.2.2 F1-Score สำหรับประเมินความแม่นยำของการสกัดข้อมูล

$$\begin{aligned} Precision &= \frac{TP}{TP + FP} \\ Recall &= \frac{TP}{TP + FN} \\ F1 &= 2 \times \frac{Precision \times Recall}{Precision + Recall} \end{aligned}$$

โดยที่ TP = จำนวนฟิลต์ที่สกัดถูกต้อง, FP = จำนวนฟิลต์ที่สกัดผิด, FN = จำนวนฟิลต์ที่ไม่ได้สกัด เกณฑ์การยอมรับ: F1-Score > 0.8

7.2.3 ขั้นตอนการประเมิน

(1) ประเมินประสิทธิภาพ OCR

- นำเอกสารตัวอย่าง 90 ฉบับ ผ่านกระบวนการ OCR
- เปรียบเทียบข้อความที่ได้กับ Ground Truth
- คำนวณ WER สำหรับแต่ละประเภทเอกสาร (Text-based vs Scanned)
- คำนวณ WER เฉลี่ยรวม

(2) ประเมินประสิทธิภาพการสกัดข้อมูล

- นำข้อความที่ได้จาก OCR ผ่านกระบวนการสกัดข้อมูล
- เปรียบเทียบข้อมูลที่สกัดได้กับ Ground Truth ทีละฟิลต์
- คำนวณ Precision, Recall และ F1-Score สำหรับแต่ละฟิลต์
- คำนวณ F1-Score เฉลี่ยรวม

(3) วิเคราะห์ข้อผิดพลาด

- ระบุประเภทข้อผิดพลาดที่พบบ่อย
- วิเคราะห์สาเหตุของข้อผิดพลาด
- เสนอแนวทางปรับปรุง

ตารางที่ 7 ตารางสรุปแผนการประเมิน

มาตรวัด	สิ่งที่ประเมิน	ขนาดตัวอย่าง	เกณฑ์ยอมรับ
WER	ความแม่นยำ OCR (Text-based PDF)	45 ฉบับ	< 5%
WER	ความแม่นยำ OCR (Scanned PDF)	45 ฉบับ	< 15%
WER	ความแม่นยำ OCR (เฉลี่ยรวม)	90 ฉบับ	< 10%
F1-Score	ความแม่นยำการสกัดข้อมูล	90 ฉบับ	> 0.8

ตารางที่ 8 ตารางสรุปขั้นตอนการดำเนินงานวิจัย


ขั้นตอน	กิจกรรม	ผลลัพธ์
5.1	ศึกษาและวิเคราะห์แหล่งข้อมูล	รายงานวิเคราะห์โครงสร้างเว็บไซต์ 3 หน่วยงาน
5.2	รวบรวมชุดข้อมูล	ชุดข้อมูลประกาศและไฟล์ PDF
5.3	ประมวลผลเอกสารเบื้องต้น	ไฟล์รูปภาพที่พร้อมสำหรับ OCR
5.4	สกัดข้อความด้วย OCR	ข้อความดิบจากเอกสาร
5.5	สกัดและจัดโครงสร้างข้อมูล	ฐานข้อมูลประกาศจัดซื้อจัดจ้าง
5.6	พัฒนาระบบและส่วนติดต่อผู้ใช้	เว็บแอปพลิเคชันที่ใช้งานได้
5.7	ประเมินผลและสรุปผล	รายงานผลการประเมินประสิทธิภาพ

บทที่ 4

การวิเคราะห์ระบบ และพัฒนาโปรแกรม

1. การวิเคราะห์ระบบ

1.1 ระบบเริ่มจากการดึงข้อมูลประกาศจัดซื้อจัดจ้างจากหลายแหล่ง (เว็บไซต์หน่วยงานท้องถิ่น, e-GP, PDF เอกสาร) นำไปกระบวนการ ETL/ELT จากนั้นทำการจัดเก็บในฐานข้อมูลกลาง แล้วนำไปแสดงผลผ่านเว็บไซต์พร้อมฟังก์ชันค้นหาและแจ้งเตือน



ภาพที่ 1 Flowchart แสดงขั้นตอนการเก็บรวบรวมข้อมูล

1.2 รายการความต้องการ (Requirements)

1.2.1 Functional Requirements


- (1) ระบบต้องรวบรวมข้อมูลจากอย่างน้อย 3 หน่วยงานในจังหวัดขอนแก่น
- (2) รองรับ OCR ภาษาไทยด้วยความแม่นยำ $\geq 90\%$ ($WER \leq 10\%$)
- (3) มีระบบค้นหาประกาศด้วยคีย์เวิร์ด, การกรองตามหน่วยงาน, ประเภทโครงการ, งบประมาณ
- (4) ระบบแจ้งเตือนผู้ใช้เมื่อมีประกาศใหม่
- (5) ผู้ดูแลระบบสามารถตรวจสอบและแก้ไขข้อมูลผิดพลาดได้

1.2.2 Non-Functional Requirements

- (1) ความปลอดภัย: ปฏิบัติตาม พ.ร.บ. คอมพิวเตอร์ และ พ.ร.บ. ข้อมูลข่าวสารของราชการ
- (2) การค้นหาต้องตอบสนองภายใน 2 วินาที
- (3) รองรับผู้ใช้งานพร้อมกัน ≥ 100 คน

1.3 Use Case Diagram


Use-Case Diagram



ภาพที่ 2 Use-Case Diagram เว็บไซต์จัดซื้อจัดจ้าง


1.4 System Sequence Diagram

Search Flow



ภาพที่ 3 Sequence Diagram ผู้ใช้ค้นหาประกาศด้วย keyword


Create Alert Rule



ภาพที่ 4 Sequence Diagram ผู้ใช้เปิดการแจ้งเตือนเมื่อประกาศที่ลงตรงกับเงื่อนไขที่ผู้ใช้กำหนดไว้

1.5 Conceptual Class Diagram

Class Diagram



ภาพที่ 5 Class Diagram แสดงความสัมพันธ์ระหว่างผู้ใช้กับระบบ

2. การออกแบบระบบ

2.1 สถาปัตยกรรมระบบ

2.1.1 Web Application, OCR Engine, Web Scraping Module

2.1.2 Cloud Server (Linux), PostgreSQL Database, Web Browser Client

บทที่ 5

บทสรุป

เอกสารอ้างอิง

1. สำนักงานส่งเสริมวิสาหกิจขนาดกลางและขนาดย่อม. สำนักงานส่งเสริมวิสาหกิจขนาดกลางและขนาดย่อม(สสว.) [อินเทอร์เน็ต]. 2565 [อ้างถึง 7 มกราคม 2026]. เข้าถึงได้จาก: <https://www.sme.go.th/>
2. กรมส่งเสริมการปกครองท้องถิ่น. กรมส่งเสริมการปกครองท้องถิ่น [อินเทอร์เน็ต]. 2568 [อ้างถึง 7 มกราคม 2026]. เข้าถึงได้จาก: <https://www.dla.go.th/index.do>
3. สำนักงาน ก.พ.ร . สำนักงานคณะกรรมการพัฒนาระบบราชการ [อินเทอร์เน็ต]. 23 พฤศจิกายน 2023 [อ้างถึง 5 มกราคม 2026]. เข้าถึงได้จาก: <https://www.opdc.go.th/home/>
4. ธนาคารแห่งประเทศไทย. ธนาคารแห่งประเทศไทย [อินเทอร์เน็ต]. 2567 [อ้างถึง 6 มกราคม 2026]. เข้าถึงได้จาก: <https://www.bot.or.th/th/home.html>
5. ธรรมวิเศษ ศ, สมรภูมิ ช, ลาภจิตร ส. แนวทางการพัฒนาการจัดซื้อจัดจ้างภาครัฐด้วยระบบอิเล็กทรอนิกส์ (ระบบ e-GP) ขององค์กรปกครองส่วนท้องถิ่นในอำเภอโนนนารายณ์ จังหวัดสุรินทร์. วารสารมหาจุฬาลงกรณราชวิทยาลัย. 2567;15(2):244-60.
6. สงแทน ๒, อาเมน อ, ภูวนาถนรานูบาล ก. การพัฒนาระบบติดตามการจัดซื้อจัดจ้างและการใช้งบประมาณโดยภูมิศาสตร์. Mahidol R2R E-J. 2564;8(2):133-46. doi:10.14456/jmu.2021.25

7. Adhikari NS, Agarwal S. A Comparative Study of PDF Parsing Tools Across Diverse Document Categories [อินเทอร์เน็ต]. arXiv; 2025 [อ้างถึง 11 ธันวาคม 2025]. เข้าถึงได้จาก: <http://arxiv.org/abs/2410.09871> doi:10.48550/arXiv.2410.09871
8. Taoufik AO, Azmani A. AI-Enhanced Techniques for Extracting Structured Data from Unstructured Public Procurement Documents. ใน: 2024 8th International Symposium on Innovative Approaches in Smart Technologies (ISAS) [อินเทอร์เน็ต]. IEEE; 2024 [อ้างถึง 11 ธันวาคม 2025]. น. 1–8. เข้าถึงได้จาก: <https://ieeexplore.ieee.org/abstract/document/10845583/>
9. Liu Y, Li S, Huang K, Wang Q. AutoIE: An Automated Framework for Information Extraction from Scientific Literature. ใน: Cao C, Chen H, Zhao L, Arshad J, Asyhari T, Wang Y, บรรณาธิการ. Knowledge Science, Engineering and Management [อินเทอร์เน็ต]. Singapore: Springer Nature Singapore; 2024 [อ้างถึง 11 ธันวาคม 2025]. น. 424–36. (Lecture Notes in Computer Science). เข้าถึงได้จาก: https://link.springer.com/10.1007/978-981-97-5495-3_32 doi:10.1007/978-981-97-5495-3_32
10. กรมบัญชีกลาง. เว็บไซต์อินเทอร์เน็ตกรมบัญชีกลาง [อินเทอร์เน็ต]. 2560 [อ้างถึง 5 มกราคม 2026]. เข้าถึงได้จาก: <https://www.cgd.go.th/cs/internet/internet/หน้าหลัก2.html>
11. Google Cloud. Google Cloud [อินเทอร์เน็ต]. 2023 [อ้างถึง 5 มกราคม 2026]. What is ETL? เข้าถึงได้จาก: <https://cloud.google.com/learn/what-is-etl>
12. สำนักงานคณะกรรมการกฤษฎีกา. สำนักงานคณะกรรมการกฤษฎีกา [อินเทอร์เน็ต]. 2550 [อ้างถึง 7 มกราคม 2026]. เข้าถึงได้จาก: <https://searchlaw.ocs.go.th/council-of-state/#/public/doc/ZC9wWkVOT1ZpQVpCRnQ2UVk1K0k4Zz09>
13. สำนักงานคณะกรรมการกฤษฎีกา. สำนักงานคณะกรรมการกฤษฎีกา [อินเทอร์เน็ต]. 2540 [อ้างถึง 7 มกราคม 2026]. เข้าถึงได้จาก: <https://searchlaw.ocs.go.th/council-of-state/#/public/doc/Nmh2RnBRYW1vRVlCUXVhZXZ0TlB5QT09>
14. Essien IA, Adebayo AO, Afuwape AA, Eboseremen BO, Oladega F, Soneye OM. The Ethics of Web Scraping in Research: A Review: Investigating the boundaries, legal implications, and societal acceptance of web scraping as a data collection method. J Front Multidiscip Res. 2023;4(1):529–38.

15. Smith R. An Overview of the Tesseract OCR Engine. ใน: Ninth International Conference on Document Analysis and Recognition (ICDAR 2007) [อินเทอร์เน็ต]. 2007 [อ้างถึง 5 มกราคม 2026]. น. 629–33. เข้าถึงได้จาก: <https://ieeexplore.ieee.org/document/4376991>
doi:10.1109/ICDAR.2007.4376991

16. Wick C, Reul C, Puppe F. Comparison of OCR Accuracy on Early Printed Books using the Open Source Engines Calamari and OCRopus. J Lang Technol Comput Linguist. 1 กรกฎาคม 2018;33(1):79–96. doi:10.21248/jlcl.33.2018.219

17. Chamchong R, Saisangchan U, Pawara P. Correction to: Thai Handwritten Recognition on BEST2019 Datasets Using Deep Learning. ใน: Chomphuwiset P, Kim J, Pawara P, บรรณาธิการ. Multi-disciplinary Trends in Artificial Intelligence. Cham: Springer International Publishing; 2021. น. C1–C1. doi:10.1007/978-3-030-80253-0_17

18. Klakow D, Peters J. Testing the correlation of word error rate and perplexity. Speech Commun. 1 กันยายน 2002;38(1):19–28. doi:10.1016/S0167-6393(01)00041-3